

¿Qué factores sociales, demográficos y geográficos influyen en las tendencias de homicidios en Estados Unidos?

Ospina González, E.
Facultad de Ingeniería
Universidad de Antioquia
Medellin, Antioquia
estiven.ospinag@udea.edu.co

García Álvarez, Juan J.
Facultad de Ingeniería
Universidad de Antioquia
Medellin, Antioquia
juan.garcia140@udea.edu.co

Abstract—This article presents an exploratory data analysis of a homicide dataset from the United States covering the period between 1980 and 2014. The dataset contains demographic, social, temporal, and geographic information related to victims and perpetrators, including variables such as age, sex, relationship between individuals involved, type of weapon used, location, and date of the incident. The main objective of this study is to identify possible factors and patterns associated with homicide trends through the application of data science techniques.

To achieve this, different stages of the data analysis lifecycle were applied, including exploratory data analysis (EDA), univariate, bivariate, and multivariate analysis, data transformation, normalization of categorical and numerical variables, outlier detection, and missing value treatment. These processes allow a deeper understanding of the behavior of the dataset and support the identification of relevant variables, hidden relationships, and natural behavioral patterns associated with homicide events. The study seeks to contribute to the interpretation of social and demographic factors influencing homicide dynamics using a data-driven analytical approach.

Index Terms—data science analysis, homicide, KNN imputation, outliers detection, EDA, behavior patterns

I. INTRODUCCIÓN

La violencia y los homicidios representan una problemática social compleja que impacta directamente la seguridad, la estabilidad social y la calidad de vida de las personas. Comprender los factores asociados a este fenómeno requiere no solo observar cifras generales, sino también analizar las relaciones existentes entre variables sociales, demográficas, temporales y geográficas que puedan influir en los patrones de comportamiento relacionados con los homicidios. En este contexto, el análisis de datos se convierte en una herramienta importante para identificar tendencias, relaciones y posibles factores asociados a este tipo de eventos.

El presente artículo aborda el análisis exploratorio de un conjunto de datos sobre homicidios ocurridos en Estados Unidos entre los años 1980 y 2014. El dataset contiene información detallada sobre víctimas y perpetradores, incluyendo variables relacionadas con edad, sexo, relación entre las personas involucradas, ubicación geográfica, fechas de ocurrencia y tipo de arma utilizada, entre otras características relevantes.

A partir de esta información, se busca identificar comportamientos y patrones que permitan comprender de manera más profunda algunos factores que podrían influir en la ocurrencia de homicidios.

Para el desarrollo del análisis se implementan distintas etapas propias del ciclo de vida de los datos y de los procesos de ciencia de datos. Inicialmente, se realiza un análisis exploratorio profundo (EDA), acompañado de análisis univariado, bivariado y multivariado, con el propósito de comprender el comportamiento individual y conjunto de las variables. Posteriormente, se aplican procesos de transformación y preparación de datos, incluyendo normalización de formatos, tratamiento de variables categóricas, revisión de coherencia de atributos y estandarización de información.

Asimismo, se realiza detección y análisis de datos atípicos considerando el contexto de las variables, evitando eliminar información que pueda resultar relevante para la interpretación del fenómeno estudiado. También se implementan estrategias de imputación y validación de datos faltantes cuando estas aportan valor analítico al estudio. Todo este proceso busca garantizar una mejor calidad de los datos y permitir análisis más consistentes y precisos.

Finalmente, el objetivo principal de este trabajo es aplicar técnicas de ciencia de datos para identificar patrones y relaciones significativas dentro del dataset, permitiendo comprender mejor cómo diferentes factores sociales, demográficos y geográficos pueden estar asociados a las tendencias de homicidios en Estados Unidos. A través de este enfoque, se espera generar hallazgos relevantes que contribuyan a la interpretación y análisis de este tipo de problemáticas desde una perspectiva basada en datos.

II. DESCRIPCIÓN DEL PROBLEMA

A. Contexto del problema

Los homicidios representan una de las problemáticas sociales más complejas debido al impacto que generan sobre la seguridad, la convivencia y la estabilidad social de una población. Más allá de las cifras generales, este fenómeno involucra múltiples factores sociales, demográficos, temporales

y geográficos que pueden influir en su comportamiento y evolución a lo largo del tiempo. Comprender estas relaciones resulta importante para identificar patrones y tendencias que permitan interpretar mejor las dinámicas asociadas a este tipo de eventos.

En este trabajo se utiliza un conjunto de datos obtenido desde la plataforma Kaggle, el cual contiene información detallada sobre homicidios ocurridos en Estados Unidos entre los años 1980 y 2014. El dataset incluye variables relacionadas tanto con las víctimas como con los perpetradores, además de información sobre ubicación geográfica, fechas de ocurrencia, tipo de arma utilizada, relación entre las personas involucradas y estado de resolución del caso. Esta información permite realizar análisis desde diferentes perspectivas con el objetivo de encontrar comportamientos y relaciones relevantes dentro de los registros históricos disponibles.

A través de técnicas de ciencia de datos y análisis exploratorio, este estudio busca identificar factores que puedan influir en las tendencias de homicidios presentes en el dataset. Para ello, se aplican procesos de limpieza, transformación y análisis de datos que permitan trabajar con información más consistente y adecuada para la interpretación de resultados. [2].

B. Composición de la base de datos

El conjunto de datos original está compuesto por un total de 638,454 registros y 24 variables. Cada registro representa un caso de homicidio y contiene información relacionada con características de la víctima, del perpetrador y del contexto en el que ocurrió el evento. Entre las variables disponibles se encuentran datos como sexo, edad, raza, relación entre víctima y perpetrador, tipo de arma utilizada, ciudad, estado, año del homicidio y estado de resolución del caso.

Las variables del dataset incluyen tanto atributos numéricos como categóricos, temporales y geográficos, lo que permite realizar diferentes tipos de análisis estadísticos y exploratorios. La riqueza de la información disponible hace posible estudiar patrones relacionados con edades, tipos de armas, distribución geográfica de homicidios, relaciones entre involucrados y otros factores sociales asociados a los eventos registrados.

Sin embargo, durante la exploración inicial se identificó que gran parte de los registros presentaban valores nulos o vacíos principalmente en las variables asociadas al perpetrador. Esto ocurre debido a la naturaleza de las investigaciones criminales, ya que muchos casos no fueron resueltos. El dataset cuenta con una variable denominada Crime Solved, la cual indica si un caso fue resuelto o no. A partir de este criterio se observó que la mayoría de los datos faltantes relacionados con el perpetrador correspondían a homicidios sin resolver. [1].

C. Calidad de los datos

Durante las etapas iniciales de exploración y análisis se identificaron diferentes problemáticas relacionadas con la calidad de los datos. Entre los principales inconvenientes encontrados se destacan la presencia de valores nulos, inconsistencias en el tipado de variables, registros con valores desconocidos y datos potencialmente atípicos.

Uno de los casos más relevantes se presentó en la variable Perpetrator Age, la cual originalmente se encontraba registrada como tipo objeto debido a la existencia de valores como "Unknown", 0 y 99. Estas inconsistencias impedían tratar correctamente la variable como un atributo numérico y afectaban los análisis estadísticos posteriores. Por esta razón, fue necesario aplicar procesos de transformación y limpieza que permitieran normalizar el contenido de la variable y convertirla a un formato adecuado para el análisis.

Asimismo, se identificaron diferencias en formatos de fechas, presencia de categorías escritas de manera inconsistente y registros con información incompleta. Debido a esto, se aplicaron procesos de estandarización sobre variables categóricas, incluyendo normalización de texto, uso de formatos homogéneos y validaciones de coherencia entre atributos.

Es importante resaltar que no todos los valores faltantes fueron considerados errores del dataset. En muchos casos, la ausencia de información respondía directamente a la naturaleza de los homicidios no resueltos. Por esta razón, las decisiones de limpieza y transformación se realizaron considerando el contexto de los datos y evitando eliminar información que pudiera aportar valor al análisis general del estudio.

III. METODOLOGÍA

El desarrollo de este trabajo se realizó siguiendo las etapas del ciclo de vida de los datos, aplicando técnicas de análisis exploratorio y preparación de información orientadas a garantizar la calidad, consistencia y confiabilidad de los resultados obtenidos. Para ello, se tomaron como referencia las metodologías y prácticas propuestas en el repositorio académico guía utilizado durante el desarrollo del proyecto. [2].

La metodología implementada se estructuró en diferentes fases: comprensión del problema, comprensión de los datos, preparación de la información, análisis exploratorio y tratamiento de variables.

A. Comprensión del problema

En la primera etapa se realizó un análisis del contexto del problema con el propósito de comprender la naturaleza del fenómeno estudiado y definir los objetivos del trabajo. A partir de ello, se estableció la necesidad de analizar el comportamiento de los homicidios registrados en Estados Unidos entre 1980 y 2014, buscando identificar patrones sociales, demográficos y geográficos que pudieran influir en la ocurrencia de estos eventos.

Durante esta fase se definieron preguntas orientadoras relacionadas con variables como edad, sexo, ubicación geográfica, relación entre víctima y perpetrador, tipo de arma utilizada y comportamiento temporal de los homicidios. Esto permitió establecer el enfoque analítico del estudio y delimitar las técnicas de ciencia de datos necesarias para abordar el problema.

B. Comprensión de los datos

Posteriormente, se realizó una exploración inicial del conjunto de datos con el objetivo de comprender su estructura, composición y calidad. Para ello, se analizaron las 24 variables disponibles y los 638.454 registros originales del dataset, identificando atributos categóricos, numéricos, temporales y geográficos.

En esta fase se aplicaron técnicas de análisis descriptivo y estadístico inicial para reconocer:

- 1) Distribución de variables.
- 2) Presencia de valores faltantes.
- 3) Tipos de datos.
- 4) Cardinalidad de variables categóricas.
- 5) Posibles inconsistencias de registro.
- 6) Comportamiento general de la información.




Fig. 1. Distribución variables numéricas.

Además, se evaluó la relación entre determinadas variables relevantes para el estudio, identificando patrones preliminares asociados a homicidios según ubicación, sexo, edad, armas utilizadas y relaciones entre víctimas y perpetradores.

C. Herramientas y librerías utilizadas

El desarrollo del análisis se realizó utilizando el lenguaje de programación Python junto con diferentes librerías orientadas al procesamiento, análisis y visualización de datos.

Entre las principales herramientas utilizadas se encuentran:

- 1) **Pandas**: manipulación, limpieza y transformación de datos.
- 2) **NumPy**: operaciones matemáticas y manejo de estructuras numéricas.
- 3) **Matplotlib**: generación de gráficos y visualizaciones estadísticas.
- 4) **Seaborn**: visualización avanzada y análisis exploratorio gráfico.
- 5) **Scikit-learn (sklearn.preprocessing)**: transformación y normalización de variables.
- 6) **Scikit-learn (sklearn.impute)**: Imputación de datos faltantes.

Estas herramientas permitieron desarrollar procesos de análisis exploratorio, transformación de variables y preparación de datos de manera estructurada y reproducible.

D. Preparación y transformación de los datos

Luego de comprender la estructura del dataset, se desarrolló una fase de preparación de datos enfocada en mejorar la consistencia y calidad de la información utilizada en el análisis.

Durante esta etapa se realizaron actividades como:

- 1) Limpieza de registros.
- 2) Estandarización de formatos.
- 3) Validación de coherencia entre atributos.
- 4) Transformación de tipos de datos.
- 5) normalización de variables categóricas.

Entre los principales procesos aplicados se encuentran:

- 1) Conversión de variables con tipado incorrecto.
- 2) Unificación de formatos de fecha.
- 3) Aplicación de funciones `lower()` y `strip()` sobre variables categóricas.
- 4) Tratamiento de valores "Unknown" o inconsistentes.
- 5) Validación de registros duplicados o incompletos.




Fig. 2. Matriz de Missingness por Variable.

Asimismo, se aplicó un criterio contextual para el tratamiento de variables categóricas y numéricas, evitando transformaciones innecesarias que pudieran generar pérdida de información o aumentar excesivamente la dimensionalidad del dataset.

En variables categóricas de alta cardinalidad se evaluó cuidadosamente el uso de técnicas de codificación, considerando el posible impacto de la maldición de la dimensionalidad sobre el análisis posterior.

E. Análisis exploratorio de datos (EDA)

El análisis exploratorio de datos (EDA) permitió comprender el comportamiento de las variables y detectar relaciones relevantes dentro del conjunto de datos. Para ello, se implementaron técnicas de análisis:

- 1) Univariado.
- 2) Bivariado.
- 3) Multivariado.

En el análisis univariado se estudiaron distribuciones individuales, frecuencias y comportamiento estadístico de variables numéricas y categóricas. Posteriormente, mediante análisis bivariado y multivariado, se evaluaron relaciones entre variables sociales, geográficas y demográficas asociadas a los homicidios.

También se desarrollaron visualizaciones estadísticas que permitieron identificar tendencias temporales, concentración geográfica de homicidios, relaciones entre víctimas y perpetradores y patrones asociados al uso de armas.

F. Detección y tratamiento de datos atípicos

Durante el análisis se identificaron valores atípicos presentes en diferentes variables numéricas, especialmente en atributos relacionados con edades y conteos asociados a homicidios.

Sin embargo, el tratamiento de datos atípicos se realizó considerando el contexto específico de cada variable. En este estudio, algunos valores extremos podían representar comportamientos reales asociados al fenómeno analizado y no necesariamente errores de captura o registro. Por esta razón, no todos los outliers fueron eliminados automáticamente.

Las decisiones de transformación, conservación o exclusión de datos atípicos se realizaron evaluando su impacto sobre la interpretación y representatividad de la información.

IV. ANÁLISIS Y RESULTADOS

A. Filtrado de casos resueltos y calidad de la información

Uno de los primeros hallazgos identificados durante el análisis fue la alta cantidad de valores faltantes y registros categorizados como "Unknown" en las variables relacionadas con el perpetrador. Este comportamiento se encontraba directamente asociado a la variable Crime Solved, la cual indica si un homicidio fue resuelto o no.

Se observó que los casos no resueltos presentaban una ausencia significativa de información relacionada con el victimario, especialmente en atributos como edad, etnia, relación con la víctima y sexo. Este comportamiento corresponde a una característica natural del fenómeno analizado, debido a que en investigaciones criminales sin resolver gran parte de la información del perpetrador permanece desconocida.

Por esta razón, se decidió trabajar únicamente con los casos resueltos, permitiendo reducir considerablemente la presencia de datos faltantes estructurales y mejorar la consistencia de la información utilizada en el análisis. Esta decisión también disminuyó la necesidad de aplicar procesos extensivos de imputación sobre variables relacionadas con el perpetrador.




Fig. 3. Impacto del Filtro: Crime Solved = True.

B. Comportamiento temporal de homicidios

El análisis temporal evidenció un crecimiento importante en la cantidad de homicidios registrados entre finales de la década de 1980 y mediados de los años 90. Particularmente, se identificó un pico significativo entre 1990 y 1995 en comparación con otros periodos del dataset.

Este comportamiento refleja una concentración elevada de casos durante dichos años, lo que podría estar asociado a factores sociales, económicos o criminales específicos del contexto histórico estadounidense de ese periodo. Aunque este estudio no busca explicar las causas externas de estos comportamientos, sí permite identificar tendencias temporales relevantes dentro del conjunto de datos.



Fig. 4. Homicidios registrados por año.

C. Distribución geográfica de homicidios

En cuanto a la distribución geográfica, California se destacó como el estado con mayor cantidad de homicidios registrados dentro del dataset, representando una proporción considerable frente a los demás estados analizados.

Este comportamiento puede estar relacionado tanto con factores poblacionales como con la dimensión territorial y densidad urbana del estado. Comparativamente, otros estados presentan cantidades significativamente menores de homicidios acumulados durante el mismo periodo.

TABLE I
ESTADOS CON MAYOR CANTIDAD DE HOMICIDIOS REGISTRADOS

Estado	Cantidad de homicidios
California	99.783
Texas	62.095
New York	49.268
Florida	37.164
Michigan	28.448




Fig. 5. Top 10 estados con mas homicidios registrados.

D. Tipo de armas utilizadas

El análisis de la variable Weapon permitió identificar que las armas de fuego tipo Firearm representan el mecanismo más utilizado en los homicidios registrados, con una diferencia considerable respecto a otros tipos de armas presentes en el dataset.

Este comportamiento se mantuvo consistentemente dominante frente a categorías como cuchillos, rifles, objetos contundentes u otros mecanismos de agresión. La alta frecuencia observada en armas tipo Firearm evidencia un patrón relevante dentro de los registros históricos analizados.

Adicionalmente, se aplicaron agrupamientos sobre las variables Weapon y Relationship utilizando categorías basadas en la clasificación propuesta por la Office of Juvenile Justice and Delinquency Prevention (OJJDP), permitiendo reducir dispersión categórica y obtener un mejor control analítico de la información. [3]

TABLE II
DISTRIBUCIÓN DE HOMICIDIOS SEGÚN TIPO DE ARMA

Tipo de arma	Cantidad	Porcentaje
Firearm	287.326	64.11%
Knife	74.758	16.68%
Blunt Object	51.504	11.49%
Other	34.584	7.72%

E. Tasa de resolución de casos

El análisis de la tasa de resolución mostró un comportamiento relativamente estable a lo largo de los años comprendidos entre 1980 y 2014. Los porcentajes de casos resueltos no presentan variaciones extremas durante el periodo analizado, manteniéndose cercanos al 80% anual aproximadamente.

Este comportamiento indica cierta estabilidad histórica en la capacidad de resolución de homicidios registrada dentro del dataset.




Fig. 6. Línea temporal de porcentaje de casos resueltos por año.

F. Distribución por sexo de las víctimas

Uno de los patrones más notorios identificados corresponde a la distribución por sexo de las víctimas. El análisis evidenció una clara predominancia de víctimas masculinas, representando aproximadamente el 77.4% del total de registros analizados.

Este comportamiento refleja una tendencia consistente en prácticamente todos los periodos observados dentro del dataset.




Fig. 7. Distribución de Sexo de las Víctimas

G. Estados con mayor tasa de resolución

Al analizar la proporción de casos resueltos respecto al total de homicidios registrados por estado, se identificó que estados como North Dakota, Montana y South Dakota presentan las tasas de resolución más altas del dataset.

Particularmente, North Dakota registró aproximadamente un 93.18% de casos resueltos. Este comportamiento puede estar relacionado con el menor volumen total de homicidios presentes en dichos estados, facilitando potencialmente los

procesos investigativos y de resolución en comparación con estados con alta concentración de casos como California.

TABLE III
ESTADOS CON MAYOR TASA DE RESOLUCIÓN DE HOMICIDIOS

Estado	Tasa de resolución
North Dakota	93.18%
Montana	92.67%
South Dakota	91.85%

H. Resultados del análisis multivariado

La matriz de correlación permitió identificar relaciones importantes entre distintas variables del conjunto de datos, evidenciando patrones estructurales y dependencias internas relevantes para el análisis posterior. Una de las correlaciones más altas encontradas corresponde a las variables Agency Code y State con un coeficiente cercano a 0.99. Este comportamiento sugiere que ambas variables contienen información muy similar, ya que los códigos de agencia se encuentran estrechamente asociados al estado donde ocurre el homicidio. Desde una perspectiva analítica, conservar ambas variables podría introducir redundancia dentro del modelo, por lo que sería recomendable considerar la eliminación de una de ellas en futuras etapas de modelamiento.

De igual forma, se observó una correlación extremadamente alta entre Record ID, Year e Incident. Este comportamiento era esperado debido a la naturaleza secuencial de estas variables. El identificador del registro incrementa conforme avanzan los años y los incidentes registrados, lo que implica que Record ID funciona más como una variable administrativa que como una característica con valor predictivo real. Por esta razón, mantenerla dentro del análisis podría generar sesgos relacionados con la secuencia temporal y no con patrones inherentes al fenómeno de homicidios.

Otra relación importante identificada corresponde a las variables asociadas con el estado de resolución del crimen (Crime Solved). Se encontraron correlaciones moderadas con variables como Perpetrator Age, Relationship y Perpetrator Sex. Sin embargo, estos resultados no deben interpretarse directamente como factores causales de resolución del caso. En realidad, reflejan un comportamiento natural del dataset: cuando un crimen se encuentra resuelto, existe mayor disponibilidad de información relacionada con el perpetrador. Por el contrario, en los casos no resueltos predominan registros vacíos o categorizados como Unknown, lo cual incrementa artificialmente ciertas correlaciones.

Asimismo, se identificaron relaciones relevantes entre variables demográficas de víctima y perpetrador, particularmente en Race y Ethnicity. Las correlaciones observadas sugieren que una proporción considerable de homicidios ocurre entre individuos pertenecientes a contextos sociales o comunidades similares. Aunque estas relaciones no permiten establecer conclusiones causales, sí evidencian patrones demográficos importantes que podrían estar relacionados con factores geográficos, culturales o socioeconómicos.

En términos generales, la matriz de correlación mostró que gran parte de las variables poseen correlaciones bajas o moderadas, indicando que el fenómeno de homicidios es altamente complejo y multifactorial. Esto sugiere que no existe una única variable dominante capaz de explicar el comportamiento general de los datos, sino una combinación de factores sociales, temporales, geográficos y demográficos que interactúan entre sí.




Fig. 8. Matriz de correlación - análisis multivariado

I. Análisis de componentes principales (PCA)

El análisis de componentes permitió evaluar cómo se distribuye la varianza dentro del conjunto de datos y determinar el nivel de complejidad estructural presente en las variables analizadas. Los resultados evidenciaron que el primer componente (PC1) únicamente logra explicar aproximadamente el 13% de la varianza total, indicando que ninguna variable o conjunto reducido de variables domina completamente la estructura del dataset.

A diferencia de otros problemas donde pocos componentes concentran la mayor parte de la información, en este caso la varianza se encuentra distribuida entre múltiples dimensiones. Los componentes posteriores continúan aportando porcentajes relativamente similares de información, lo cual refleja que el comportamiento de los homicidios depende de numerosos factores y no puede simplificarse fácilmente en unas pocas variables principales.

Adicionalmente, el análisis de varianza acumulada mostró que se requieren aproximadamente 13 componentes principales para explicar el 80% de varianza y cerca de 16 componentes para superar el 90%. Este resultado confirma que el dataset posee una naturaleza altamente multidimensional y heterogénea. Variables relacionadas con ubicación geográfica, edad, sexo, tipo de arma, relaciones entre víctima y perpetrador, temporalidad y características demográficas contribuyen conjuntamente al comportamiento global de los homicidios.

Finalmente, el PCA permitió confirmar que el fenómeno estudiado no presenta una estructura simple o lineal, sino una combinación compleja de variables sociales y criminalísticas. Esto refuerza la necesidad de emplear estrategias de análisis

multivariado y modelos capaces de capturar relaciones no triviales dentro de los datos.




Fig. 9. Análisis de Componentes Principales

J. Eliminación de variables con bajo aporte analítico

Durante el proceso de preparación y depuración de los datos se decidió eliminar algunas variables que presentaban bajo aporte analítico, alta concentración de valores repetitivos o una limitada capacidad para contribuir significativamente al análisis de patrones de homicidios.

Algunas de las variables descartadas fueron Perpetrator Ethnicity y Victim Ethnicity, debido a la elevada cantidad de datos faltantes y registros clasificados como "Unknown" presentes en la información original. Aunque ambas variables únicamente contenían las categorías Hispanic y Not Hispanic, el alto porcentaje de valores desconocidos dificultaba la identificación de patrones confiables dentro de la data.

Adicionalmente, aplicar técnicas de imputación como la moda habría implicado asignar masivamente una de las dos categorías predominantes, introduciendo un sesgo significativo en la distribución original de los datos y afectando potencialmente futuros análisis. Por esta razón, se consideró más adecuado excluir estas variables del proceso analítico, evitando incorporar información artificialmente balanceada o poco representativa del comportamiento real del dataset.

De igual manera, se decidió ignorar las variables Victim Count y Perpetrator Count. Según la documentación asociada al dataset en Kaggle, estas variables representan el número adicional de víctimas o perpetradores involucrados en la escena del crimen aparte del caso principal registrado. Sin embargo, al analizar su distribución, se encontró que más de 500.000 registros presentaban el valor 0 en ambas columnas, lo que evidencia una variabilidad extremadamente baja dentro del conjunto de datos.

Debido a este comportamiento, dichas variables aportaban poca información útil para identificar patrones relevantes o mejorar procesos posteriores de análisis. Mantenerlas dentro del dataset podía introducir ruido innecesario y aumentar la dimensionalidad sin generar beneficios significativos en términos analíticos. Por esta razón, se optó por excluirlas del proceso principal de análisis de datos.

TABLE IV
VARIABLES CON BAJO APOORTE ANALÍTICO

Variable	Cantidad	Porcentaje
Victim Count	410.234 registros	91.53%
Perpetrator Count	374.769 registros	83.62%
Perpetrator Ethnicity	256.374 registros	57.20%
Victim Ethnicity	255.032 registros	56.90 %

K. Comportamiento mensual de homicidios

El análisis mensual permitió identificar patrones temporales recurrentes dentro de los homicidios registrados entre 1980 y 2014. Se observó que los meses de julio y agosto presentan picos superiores frente a otros meses del año, superando frecuentemente los 7.000 casos acumulados por periodos analizados.

Particularmente:

- 1) Julio registró el mayor número de homicidios con un total de 40.115 casos (9.28%).
- 2) Febrero presentó la menor cantidad con 32.025 casos (7.41%).

Estos comportamientos evidencian variaciones temporales que podrían estar relacionadas con factores sociales o estacionales presentes durante determinados periodos del año.

TABLE V
MESES CON MAYOR Y MENOR CANTIDAD DE HOMICIDIOS

Mes	Cantidad	Porcentaje
Julio	40.115	9.28%
Febrero	32.025	7.41%




Fig. 10. Conteo de Homicidios por Mes (1980-2014)




Fig. 11. Tendencia mensual por periodo de 5 años(1980-2014)

L. Tratamiento de datos faltantes y registros nulos

Durante el proceso de limpieza y preparación de los datos se identificaron variables que contenían valores nulos o registros clasificados como "Unknown" en proporciones relativamente bajas respecto al total del dataset procesado. Debido a que estos casos representaban un porcentaje reducido de la información total, se decidió eliminar directamente dichos registros que representará < 2% respecto al total de registros en lugar de aplicar técnicas de imputación.

El esfuerzo computacional y analítico requerido para imputar estas observaciones resultaba poco significativo frente al impacto real que tendrían sobre el dataset.

Posteriormente, aplicando este criterio de limpieza sobre todas las variables seleccionadas para el análisis, el conjunto de datos pasó de 448.172 registros a 432.392 registros finales, eliminando aproximadamente 15.780 observaciones, equivalentes al 3.52% del total de la data procesada.

TABLE VI
REDUCCIÓN DE REGISTROS DURANTE EL TRATAMIENTO DE DATOS FALTANTES

Descripción	Cantidad
Dataset inicial filtrado	448.172
Registros eliminados	15.780
Porcentaje eliminado	3.52%
Dataset final procesado	432.392

M. Transformación y codificación de variables categóricas

Una vez finalizado el tratamiento de datos faltantes y procesos de limpieza, se realizó un análisis detallado sobre las variables categóricas presentes en el dataset con el objetivo de determinar cuáles requerían transformación para su posterior utilización en procesos analíticos y de modelado.

Dependiendo de la naturaleza de cada variable, se evaluó la aplicación de diferentes técnicas de codificación como *Label Encoding* u *Ordinal Encoding*. Para variables con comportamiento ordinal, se hizo uso de *Ordinal Encoding*, y para categorías sin comportamiento ordinal o jerárquico, se usó *Label Encoding*.

Durante este proceso se tuvo especial cuidado con el riesgo asociado a la maldición de la dimensionalidad, evitando aplicar *One-Hot Encoding* sobre las variables de manera innecesaria. La generación excesiva de columnas derivadas podría incrementar considerablemente la dimensionalidad del dataset, afectando tanto el rendimiento computacional como la capacidad de generalización de futuros modelos analíticos o predictivos.

Por esta razón, antes de aplicar cualquier técnica de transformación categórica, se evaluó la cardinalidad de cada variable, su relevancia analítica y la posible contribución que tendría dentro del análisis general del comportamiento de homicidios.

Es importante considerar que el uso de *Label Encoding* en categorías como City o State puede suponer un riesgo dependiendo de si se quiere usar algún modelo específico en el trabajo futuro. Esto es aceptable en modelos que no asumen orden como Árboles de Decisión o Random Forst. Sin embargo, si se quiere usar un modelo lineal como Regresión Logística o SVM, es mejor plantear otra alternativa de codificación, ya que asignar números enteros sin un orden real puede confundir al modelo, dándole a entender que una ciudad o estado es "mayor" que otro.

N. Relación entre víctima y perpetrador

El análisis de la variable Relationship, posterior al agrupamiento categórico basado en la metodología propuesta por

la OJJDP [3], permitió identificar patrones relevantes respecto al vínculo existente entre la víctima y el perpetrador.

Los resultados mostraron una fuerte concentración dentro de la categoría Acquaintance, indicando que una proporción significativa de los homicidios registrados ocurrió entre personas conocidas. Este comportamiento evidencia que, en gran parte de los casos analizados, existía algún tipo de relación previa entre las partes involucradas.

Este patrón resulta relevante debido a que permite inferir posibles motivaciones sociales, personales o contextuales detrás de los homicidios, diferenciándose de eventos completamente aleatorios o cometidos entre desconocidos. Asimismo, el agrupamiento aplicado permitió reducir dispersión categórica y mejorar la interpretabilidad de las relaciones registradas originalmente en el dataset.

TABLE VII
PRINCIPALES CATEGORÍAS DE RELACIÓN ENTRE VÍCTIMA Y PERPETRADOR

Relación	Cantidad	Porcentaje
Acquaintance	180.291	40.23%
Unknown	94.892	21.17%
Stranger	87.362	19.49%
Family	85.627	19.11%

V. CONCLUSIONES

El desarrollo de este proyecto permitió evidenciar la importancia de seguir adecuadamente las fases del ciclo de vida del análisis de datos, ya que cada etapa contribuye significativamente a mejorar la comprensión, calidad y confiabilidad de la información procesada. Comprender inicialmente el contexto del problema y el objetivo del análisis facilitó identificar cuáles variables eran relevantes, qué tipo de comportamientos podían esperarse y qué dificultades podían presentarse dentro del dataset. Este entendimiento del negocio y de la problemática constituye un punto de partida fundamental para orientar correctamente las decisiones analíticas y evitar interpretaciones erróneas de los datos.

Asimismo, la etapa de exploración y preparación de los datos demostró ser una de las fases más críticas dentro del proceso. La aplicación de análisis exploratorio de datos (EDA), junto con técnicas univariadas, bivariadas y multivariadas, permitió identificar patrones relevantes, relaciones entre variables, distribuciones, anomalías y posibles sesgos presentes en la información. Procesos como la detección de datos atípicos, normalización, transformación de variables continuas y categóricas, así como la estandarización de formatos, contribuyeron a construir un conjunto de datos más consistente y preparado para futuros análisis predictivos.

Uno de los principales desafíos encontrados estuvo relacionado con el volumen de información del dataset y la alta presencia de valores "Unknown" o datos faltantes, especialmente en variables asociadas al perpetrador. Este comportamiento resultó coherente con la naturaleza de los homicidios y de las investigaciones criminales, particularmente en los

casos no resueltos, donde gran parte de la información del victimario es desconocida. En este sentido, la decisión de trabajar únicamente con casos resueltos permitió reducir considerablemente la cantidad de datos faltantes y mejorar la calidad general del análisis. Además, el apoyo de documentación y foros asociados al dataset en Kaggle fue fundamental para comprender el significado de ciertas variables y tomar decisiones más acertadas durante el preprocesamiento.

Los resultados obtenidos también permitieron identificar comportamientos relevantes dentro de los homicidios registrados en Estados Unidos entre 1980 y 2014. Se observaron patrones asociados al sexo de las víctimas, predominando significativamente los casos en hombres, así como una fuerte presencia del uso de armas de fuego tipo handgun en la mayoría de los homicidios. De igual forma, se identificaron concentraciones temporales importantes en determinados años y meses, además de diferencias considerables entre estados respecto a tasas de homicidios y resolución de casos. Estos hallazgos evidencian cómo el análisis de datos puede aportar información útil para comprender fenómenos sociales complejos y detectar tendencias relevantes dentro de grandes volúmenes de información.

Finalmente, este trabajo deja abiertas múltiples posibilidades de mejora y extensión futura. Como continuación del proyecto, podrían implementarse modelos predictivos o técnicas de machine learning que permitan estimar probabilidades de resolución de casos, identificar patrones de comportamiento criminal o detectar factores asociados a determinados tipos de homicidios. También sería posible incorporar nuevas fuentes de información externas, como variables socioeconómicas, con el objetivo de enriquecer el análisis y obtener una comprensión más profunda del fenómeno estudiado. De igual manera, futuras investigaciones podrían explorar modelos temporales o espaciales que permitan analizar la evolución de los homicidios a lo largo del tiempo y su distribución geográfica dentro de Estados Unidos.

REFERENCES

- [1] A. Harshil, "Homicide," Kaggle, 2020. Available: <https://www.kaggle.com/code/harshilalpara/homicide>
- [2] M. B. Salazar, "intro data 2026," Repositorio GitHub, 2026. Available: https://github.com/mariabda2/intro_data_2026
- [3] Office of Juvenile Justice and Delinquency Prevention, "Easy Access to the FBI's Supplementary Homicide Reports: Methods," in *OJJDP Statistical Briefing Book*, 2020. Available: <https://ojjdp.ojp.gov/statistical-briefing-book/data-analysis-tools/ezashr/methods>